Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика, искусственный интеллект и системы управления

КАФЕДРА Системы обработки информации и управления

Рубежный контроль №2

«Методы обучения с подкреплением»

ИСПОЛНИТЕЛЬ: Терентьев В.О.
ФИО

группа ИУ5-25М _____
подпись

"__"_____2023 г.

ПРЕПОДАВАТЕЛЬ: Гапанюк Ю.Е.
ФИО

_____
подпись

"__"_____2023 г.

Москва - 2023

1. Задание

Для одного из алгоритмов временных различий, реализованных Вами в соответствующей лабораторная работе:

- SARSA
- Q-обучение
- Двойное Q-обучение

осуществите подбор гиперпараметров. Критерием оптимизации должна являться суммарная награда.

2. Код программы

```
import numpy as np
import matplotlib.pyplot as plt
import gym
from tqdm import tqdm

#        ************************************        БАЗОВЫЙ        АГЕНТ
****************************************

class BasicAgent:
    '''
    Базовый агент, от которого наследуются стратегии обучения
    '''

    # Наименование алгоритма
    ALGO_NAME = '---'

    def __init__(self, env, eps=0.1):
        # Среда
        self.env = env
        # Размерности Q-матрицы
        self.nA = env.action_space.n
        self.nS = env.observation_space.n
        #и сама матрица
        self.Q = np.zeros((self.nS, self.nA))
        # Значения коэффициентов
        # Порог выбора случайного действия
        self.eps=eps
        # Награды по эпизодам
        self.episodes_reward = []
```

```
    def print_q(self):
        print('Вывод Q-матрицы для алгоритма ', self.ALGO_NAME)
        print(self.Q)


    def get_state(self, state):
        '''
        Возвращает правильное начальное состояние
        '''
        if type(state) is tuple:
                # Если состояние вернулось в виде кортежа, то вернуть
только номер состояния
            return state[0]
        else:
            return state


    def greedy(self, state):
        '''
        <<Жадное>> текущее действие
        Возвращает действие, соответствующее максимальному Q-значению
        для состояния state
        '''
        return np.argmax(self.Q[state])


    def make_action(self, state):
        '''
        Выбор действия агентом
        '''
        if np.random.uniform(0,1) < self.eps:

            # Если вероятность меньше eps
            # то выбирается случайное действие
            return self.env.action_space.sample()
        else:
            # иначе действие, соответствующее максимальному Q-значению
            return self.greedy(state)


    def draw_episodes_reward(self):
        # Построение графика наград по эпизодам
```

```
        fig, ax = plt.subplots(figsize = (15,10))
        y = self.episodes_reward
        x = list(range(1, len(y)+1))
        plt.plot(x, y, '-', linewidth=1, color='green')
        plt.title('Награды по эпизодам')
        plt.xlabel('Номер эпизода')
        plt.ylabel('Награда')
        plt.show()


    def learn():
        '''
        Реализация алгоритма обучения
        '''
        pass

#             ************************************             Q-обучение
****************************************

class QLearning_Agent(BasicAgent):
    '''
    Реализация алгоритма Q-Learning
    '''
    # Наименование алгоритма
    ALGO_NAME = 'Q-обучение'


           def   __init__(self,   env,   eps=0.4,   lr=0.1,   gamma=0.98,
num_episodes=20000):
        # Вызов конструктора верхнего уровня
        super().__init__(env, eps)
        # Learning rate
        self.lr=lr
        # Коэффициент дисконтирования
        self.gamma = gamma
        # Количество эпизодов
        self.num_episodes=num_episodes
        # Постепенное уменьшение eps
        self.eps_decay=0.00005
        self.eps_threshold=0.01


    def learn(self):
```

```
        '''
        Обучение на основе алгоритма Q-Learning
        '''
        self.episodes_reward = []
        # Цикл по эпизодам
        for ep in tqdm(list(range(self.num_episodes))):
            # Начальное состояние среды
            state = self.get_state(self.env.reset())
            # Флаг штатного завершения эпизода
            done = False
            # Флаг нештатного завершения эпизода
            truncated = False
            # Суммарная награда по эпизоду
            tot_rew = 0

                  # По мере заполнения Q-матрицы уменьшаем вероятность
случайного выбора действия
            if self.eps > self.eps_threshold:
                self.eps -= self.eps_decay

            # Проигрывание одного эпизода до финального состояния
            while not (done or truncated):

                # Выбор действия
                   # В SARSA следующее действие выбиралось после шага в
среде
                action = self.make_action(state)

                # Выполняем шаг в среде
                                next_state, rew, done, truncated, _ =
self.env.step(action)

                # Правило обновления Q для SARSA (для сравнения)
                     # self.Q[state][action] = self.Q[state][action] +
self.lr * \
                                        #           (rew + self.gamma *
self.Q[next_state][next_action] - self.Q[state][action])

                # Правило обновления для Q-обучения
                 self.Q[state][action] = self.Q[state][action] + self.lr
* \
                       (rew + self.gamma * np.max(self.Q[next_state]) -
self.Q[state][action])
```

```
                # Следующее состояние считаем текущим
                state = next_state
                # Суммарная награда за эпизод
                tot_rew += rew
                if (done or truncated):
                    self.episodes_reward.append(tot_rew)


def play_agent(agent):
    '''
    Проигрывание сессии для обученного агента
    '''
    env2 = gym.make('CliffWalking-v0', render_mode='human')
    state = env2.reset()[0]
    done = False
    while not done:
        action = agent.greedy(state)
                    next_state,  reward,  terminated,  truncated,  _  =
env2.step(action)
        env2.render()
        state = next_state
        if terminated or truncated:
            done = True


def run_q_learning():
    env = gym.make("CliffWalking-v0")

    epsilons = [0.3, 0.4, 0.5]
    learning_rates = [0.05, 0.1, 0.2]
    gammas = [0.95, 0.98, 0.99]
    num_episodes = 20000

    best_reward = float('-inf')
    best_hyperparams = None
    best_agent = None

    for eps in epsilons:
        for lr in learning_rates:
            for gamma in gammas:
                        agent  =  QLearning_Agent(env,  eps=eps,  lr=lr,
gamma=gamma, num_episodes=num_episodes)
```

```
                agent.learn()
                total_reward = sum(agent.episodes_reward)
                        print(f'Гиперпараметры: epsilon={eps}, learning
rate={lr}, gamma={gamma}, num episodes={num_episodes}')
                print(f'Суммарная награда: {total_reward}\n')

                if total_reward > best_reward:
                    best_reward = total_reward
                    best_hyperparams = (eps, lr, gamma, num_episodes)
                    best_agent = agent

        print(f'Лучшие гиперпараметры: epsilon={best_hyperparams[0]},
learning rate={best_hyperparams[1]}, gamma={best_hyperparams[2]}, num
episodes={best_hyperparams[3]}')
    print(f'Суммарная награда: {best_reward}\n')

    best_agent.print_q()
    best_agent.draw_episodes_reward()
    play_agent(best_agent)


def main():
    run_q_learning()


if __name__ == '__main__':
    main()
```

3. Результаты подбора гиперпараметров

3.1. Гиперпараметры: epsilon = 0.3, learning rate = 0.05, gamma = 0.95, num episodes = 20000

Суммарная награда: -734106

```
100%| | 20000/20000 [00:11<00:00, 1707.11it/s]
Гиперпараметры: epsilon=0.3, learning rate=0.05, gamma=0.95, num episodes=20000
Суммарная награда: -734106
```

3.2. Гиперпараметры: epsilon = 0.3, learning rate = 0.05, gamma = 0.98, num episodes = 20000

Суммарная награда: -719783

```
100%| | 20000/20000 [00:11<00:00, 1807.87it/s]
Гиперпараметры: epsilon=0.3, learning rate=0.05, gamma=0.98, num episodes=20000
Суммарная награда: -719783
```

3.3. Гиперпараметры: epsilon = 0.3, learning rate = 0.05, gamma = 0.99, num episodes = 20000

Суммарная награда: -724730

3.4. Гиперпараметры: epsilon = 0.3, learning rate = 0.1, gamma = 0.95, num episodes = 20000

Суммарная награда: -738206

3.5. Гиперпараметры: epsilon = 0.3, learning rate = 0.1, gamma = 0.98, num episodes = 20000

Суммарная награда: -723993

3.6. Гиперпараметры: epsilon = 0.3, learning rate = 0.1, gamma = 0.99, num episodes = 20000

Суммарная награда: -747135

3.7. Гиперпараметры: epsilon = 0.3, learning rate = 0.2, gamma = 0.95, num episodes = 20000

Суммарная награда: -690261

3.8. Гиперпараметры: epsilon = 0.3, learning rate = 0.2, gamma = 0.98, num episodes = 20000

Суммарная награда: -695174

3.9. Гиперпараметры: epsilon = 0.3, learning rate = 0.2, gamma = 0.99, num episodes = 20000

Суммарная награда: -697318

3.10. Гиперпараметры: epsilon = 0.4, learning rate = 0.05, gamma = 0.95, num episodes = 20000

Суммарная награда: -1187325

3.11. Гиперпараметры: epsilon = 0.4, learning rate = 0.05, gamma = 0.98, num episodes = 20000

Суммарная награда: -1187912

3.12. Гиперпараметры: epsilon = 0.4, learning rate = 0.05, gamma = 0.99, num episodes = 20000

Суммарная награда: -1187358

3.13. Гиперпараметры: epsilon = 0.4, learning rate = 0.1, gamma = 0.95, num episodes = 20000

Суммарная награда: -1067977

3.14. Гиперпараметры: epsilon = 0.4, learning rate = 0.1, gamma = 0.98, num episodes = 20000

Суммарная награда: -1073649

3.15. Гиперпараметры: epsilon = 0.4, learning rate = 0.1, gamma = 0.99, num episodes = 20000

Суммарная награда: -1085515

3.16. Гиперпараметры: epsilon = 0.4, learning rate = 0.2, gamma = 0.95, num episodes = 20000

Суммарная награда: -1085515

3.17. Гиперпараметры: epsilon = 0.4, learning rate = 0.2, gamma = 0.98, num episodes = 20000

Суммарная награда: -1001796

3.18. Гиперпараметры: epsilon = 0.4, learning rate = 0.2, gamma = 0.99, num episodes = 20000

Суммарная награда: -992852

3.19. Гиперпараметры: epsilon = 0.5, learning rate = 0.05, gamma = 0.95, num episodes = 20000

Суммарная награда: -1753563

3.20. Гиперпараметры: epsilon = 0.5, learning rate = 0.05, gamma = 0.98, num episodes = 20000

Суммарная награда: -1753563

3.21. Гиперпараметры: epsilon = 0.5, learning rate = 0.05, gamma = 0.99, num episodes = 20000

Суммарная награда: -1767028

3.22. Гиперпараметры: epsilon = 0.5, learning rate = 0.1, gamma = 0.95, num episodes = 20000

Суммарная награда: -1553120

3.23. Гиперпараметры: epsilon = 0.5, learning rate = 0.1, gamma = 0.98, num episodes = 20000

Суммарная награда: -1593516

3.24. Гиперпараметры: epsilon = 0.5, learning rate = 0.1, gamma = 0.99, num episodes = 20000

Суммарная награда: -1573441

3.25. Гиперпараметры: epsilon = 0.5, learning rate = 0.2, gamma = 0.95, num episodes = 20000

Суммарная награда: -1419773

3.26. Гиперпараметры: epsilon = 0.5, learning rate = 0.2, gamma = 0.98, num episodes = 20000

Суммарная награда: -1418196

3.27. Гиперпараметры: epsilon = 0.5, learning rate = 0.2, gamma = 0.99, num episodes = 20000

Суммарная награда: -1418465

```
100%|| 20000/20000 [00:14<00:00, 1396.09it/s]
Гиперпараметры: epsilon=0.5, learning rate=0.2, gamma=0.99, num episodes=20000
Суммарная награда: -1418465
```

4. Вывод

Лучшие гиперпараметры: epsilon = 0.3, learning rate = 0.2, gamma = 0.95, num episodes = 20000

Суммарная награда: -690261

```
Лучшие гиперпараметры: epsilon=0.3, learning rate=0.2, gamma=0.95, num episodes=20000
Суммарная награда: -690261

Вывод Q-матрицы для алгоритма  Q-обучение
[[ -10.15122819  -10.16080799  -10.15528908  -10.2115043 ]
 [  -9.78189542   -9.72532187   -9.72634666   -9.92690154]
 [  -9.52241221   -9.19199606   -9.19209058   -9.70172541]
 [  -8.78334646   -8.62394292   -8.62393363   -9.44289466]
 [  -8.55195742   -8.02524897   -8.0252482    -9.04865249]
 [  -7.96616829   -7.3950095    -7.39500978   -8.38539217]
 [  -7.28558023   -6.73159123   -6.7315912    -8.00852816]
 [  -6.57247631   -6.03325406   -6.03325406   -7.29529639]
 [  -5.99462608   -5.29816219   -5.29816219   -6.69052357]
 [  -5.24931545   -4.52438125   -4.52438125   -5.9616897 ]
 [  -4.52246015   -3.709875     -3.709875     -5.10578582]
 [  -3.64362124   -3.51325354   -2.8525       -4.40984427]
 [ -10.55568587   -9.73315833   -9.73315833  -10.24602962]
 [ -10.22844006   -9.19279825   -9.19279825  -10.24626327]
 [  -9.7310139    -8.62399815   -8.62399815   -9.73314855]
 [  -9.19262235   -8.02526122   -8.02526122   -9.19279805]
 [  -8.62385584   -7.39501181   -7.39501181   -8.62399799]
 [  -8.02524409   -6.73159137   -6.73159137   -8.02526113]
 [  -7.39501061   -6.03325408   -6.03325408   -7.39501121]
 [  -6.7315913    -5.29816219   -5.29816219   -6.73159137]
 [  -6.03325406   -4.52438125   -4.52438125   -6.03325408]
 [  -5.29816215   -3.709875     -3.709875     -5.29816211]
 [  -4.52438118   -2.8525       -2.8525       -4.5243811 ]
 [  -3.709875     -2.8525       -1.95         -3.70987483]
 [ -10.24650042   -9.19279825  -10.24650042   -9.73315833]
 [  -9.73315833   -8.62399815 -109.24650042   -9.73315833]
 [  -9.19279825   -8.02526122 -109.24650042   -9.19279825]
 [  -8.62399815   -7.39501181 -109.24650042   -8.62399815]
 [  -8.02526122   -6.73159137 -109.24650042   -8.02526122]
 [  -7.39501181   -6.03325408 -109.24650042   -7.39501181]
 [  -6.73159137   -5.29816219 -109.24650042   -6.73159137]
 [  -6.03325408   -4.52438125 -109.24650042   -6.03325408]
 [  -5.29816219   -3.709875   -109.24650042   -5.29816219]
 [  -4.52438125   -2.8525     -109.24650042   -4.52438125]
 [  -3.709875     -1.95       -109.24650042   -3.709875  ]
 [  -2.8525       -1.95         -1.           -2.8525    ]
 [  -9.73315833 -109.24650042  -10.24650042  -10.24650042]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]
 [   0.            0.            0.            0.        ]]
```

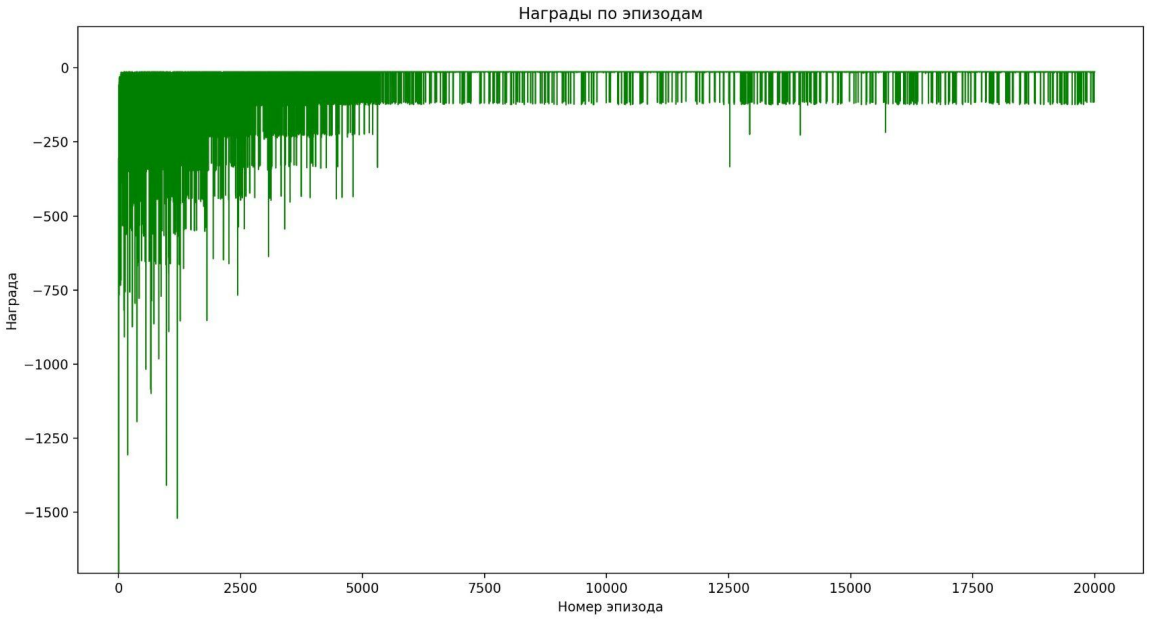

Для исходных гиперпараметров epsilon = 0.4, learning rate = 0.1, gamma = 0.98, num episodes = 20000 суммарная награда равнялась -1073649, следовательно подбор гиперпараметров помог улучшить результаты обучения и суммарную награду. Подбор гиперпараметров является важным шагом в обучении моделей и может значительно улучшить качество работы модели.